



Aeromarket


Data driven pandemic response
measures

Mariam Ali Hussain, Fabian Plett, Svenja König, Stefan Körner

Problemstellung

Supermärkte und andere essentielle Einrichtungen müssen auch in extremen Situationen offen bleiben können






Idee


- Künstliche Intelligenz nutzen um einen möglichst sicheren Betrieb zu ermöglichen
- Laufwege optimieren und analysieren
- Mögliche Problemzonen schnell identifizieren und beseitigen

Baukastenprinzip

Leicht anpassbares Framework mit dem Betreiber ihre eigenen Märkte leicht nachbauen und analysieren können (Drag & Drop Komponenten)



Retrospektive



- **Tag 1-2:** Idee konzipiert, Szene und Unity Collaborate aufgesetzt, erste Funktionen implementiert
- **Tag 3:** Kollision und Rewards
- **Tag 4-6:** Training mit verschiedenen Ansätze (Imitation Learning, manuelles Curriculum Learning) & Debugging
- **Tag 7-10:** Training & Auswertung mit verschiedenen Parametern und unterschiedlich komplexen Szenen




Testumgebung

- 3D Nachbau eines Einkaufszentrums
- Schwierigkeit: Sehr komplex zu navigieren

Agent


- Agent soll an **zufällig** gewählten Punkten Einkäufe tätigen und den Ausgang erreichen
- (Frontaler) Kontakt zu anderen Agenten wird bestraft, um **Aerosolaustausch** zu simulieren



Rewards

Ereignis	Erläuterung
Annäherung/Entfernung zum Zielobjekt	Nachteil: Wände/Hindernisse werden nicht berücksichtigt
Erreichen eines Zielsobjekts	Wenn zu niedrig, dann geht Agent schnell zum Exit
Erreichen des Ausgangs	Hoher Wert wichtig, da Agent sonst nicht zum Exit geht.
Kontakt mit Aerosolen	Abstand zu anderen Kunden
Pro Schritt/Aktion	Je schneller, desto besser

Iterationen






Minimale Test-Umgebung

Ziel: Grundsätzliche Funktionalität testen


Imitation Learning




Cumulative Reward
tag: Environment/Cumulative Reward




Episode Length
tag: Environment/Episode Length



Manuelles Curriculum Learning



Ohne Hindernisse/Wände



Mit Hindernissen/Wänden



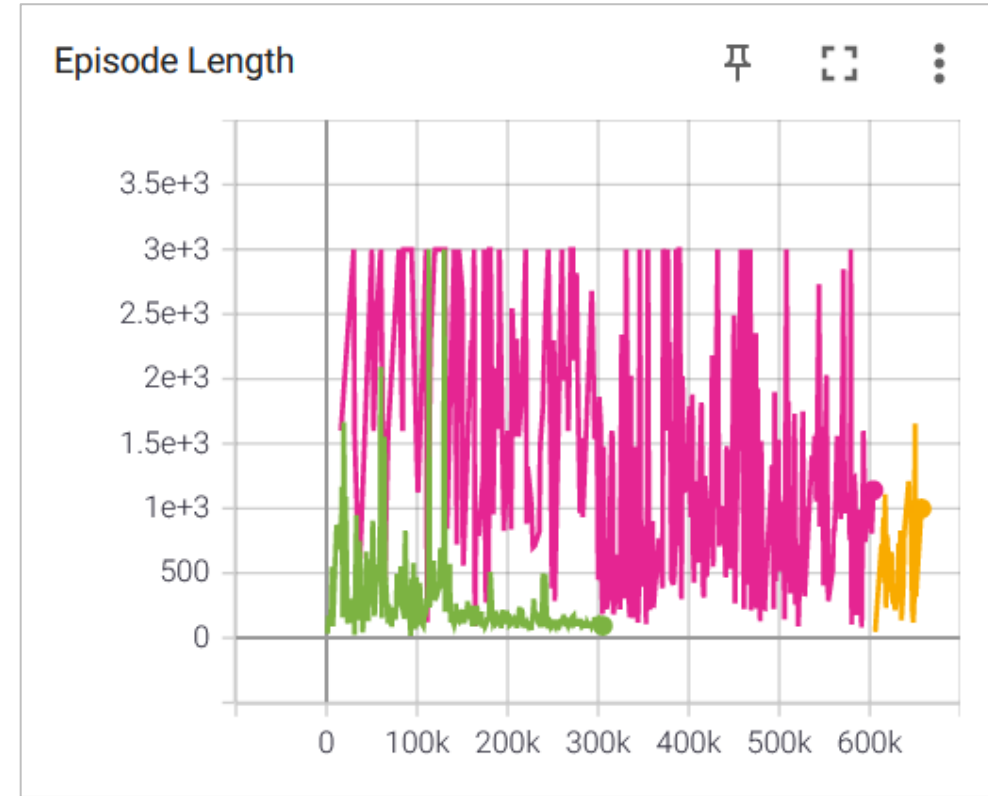

Vollständiges Einkaufscenter

Manuelles Curriculum Learning

Mit Wänden

Wände & Regale

Wände, Regale & Artikel



Kleiner Markt

Iterationen:


- 1 Agent
- Alle Agenten mit Aerosolen in Blickrichtung
- Alle Agenten mit Aerosol-Radius



Kleiner Markt





Cumulative Reward
tag: Environment/Cumulative Reward




Blickrichtung

Radius

Radius (klein)



Curriculum- RND-Ansatz



Erhöhte Netzwerkkomplexität


```
behaviors:
  Shopping:
    trainer_type: ppo
    hyperparameters:
      batch_size: 128
      buffer_size: 2048
      learning_rate: 0.0003
      beta: 0.01
      epsilon: 0.2
      lambda: 0.95
      num_epoch: 3
      learning_rate_schedule: linear
    network_settings:
      normalize: true
      hidden_units: 200
      num_layers: 2
      vis_encode_type: simple
      memory: null
    reward_signals:
      extrinsic:
        gamma: 0.99
        strength: 1.0
    keep_checkpoints: 5
    checkpoint_interval: 500000
    max_steps: 2000000
    time_horizon: 64
    summary_freq: 500
    threaded: true
```



(rnd = „Random
Network Distillation“)

```
network_settings:
  normalize: false
  hidden_units: 512
  num_layers: 3
  vis_encode_type: simple
  memory: null
  reward_signals:
    extrinsic:
      gamma: 0.99
      strength: 1.0
  rnd:
    gamma: 0.99
    strength: 0.1
    encoding_size: 64
    learning_rate: 0.0001
```

Cumulative Reward
tag: Environment/Cumulative Reward




RND mit komplexer Umgebung


- Deutlich bessere Ergebnisse als bisherige Ansätze
- Aber maximal 1/5 des Optimums

RND mit vereinfachter Umgebung

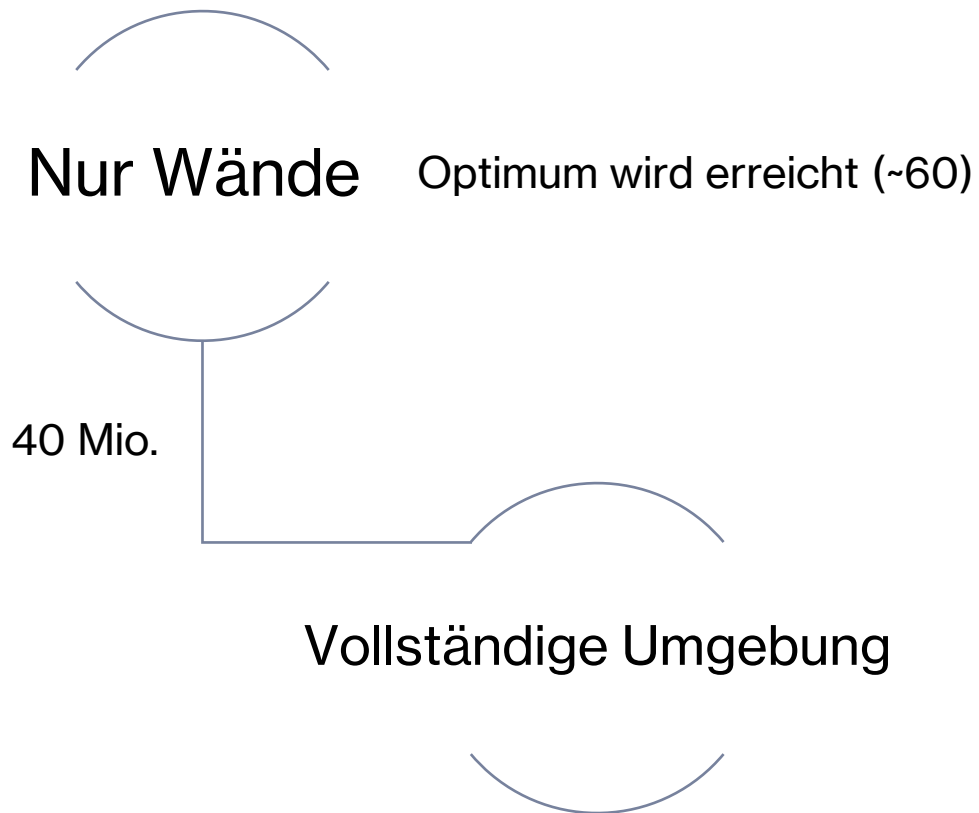
- Komplexitätsreduktion der Umgebung
- Optimum kann erreicht werden




people_StreetMan_Black-1-2
people_Sheriff_Black-1-2
people_RoadWorker_White-1-2
people_FireFighter_White-0-2
people_Hobo_Black-0-2
people_Hobo_Brown-2-2
people_HouseWife_White-1-2
people_Pimp_Brown-0-2
people_Pimp_White-1-2
people_Doctor_Brown-2-2



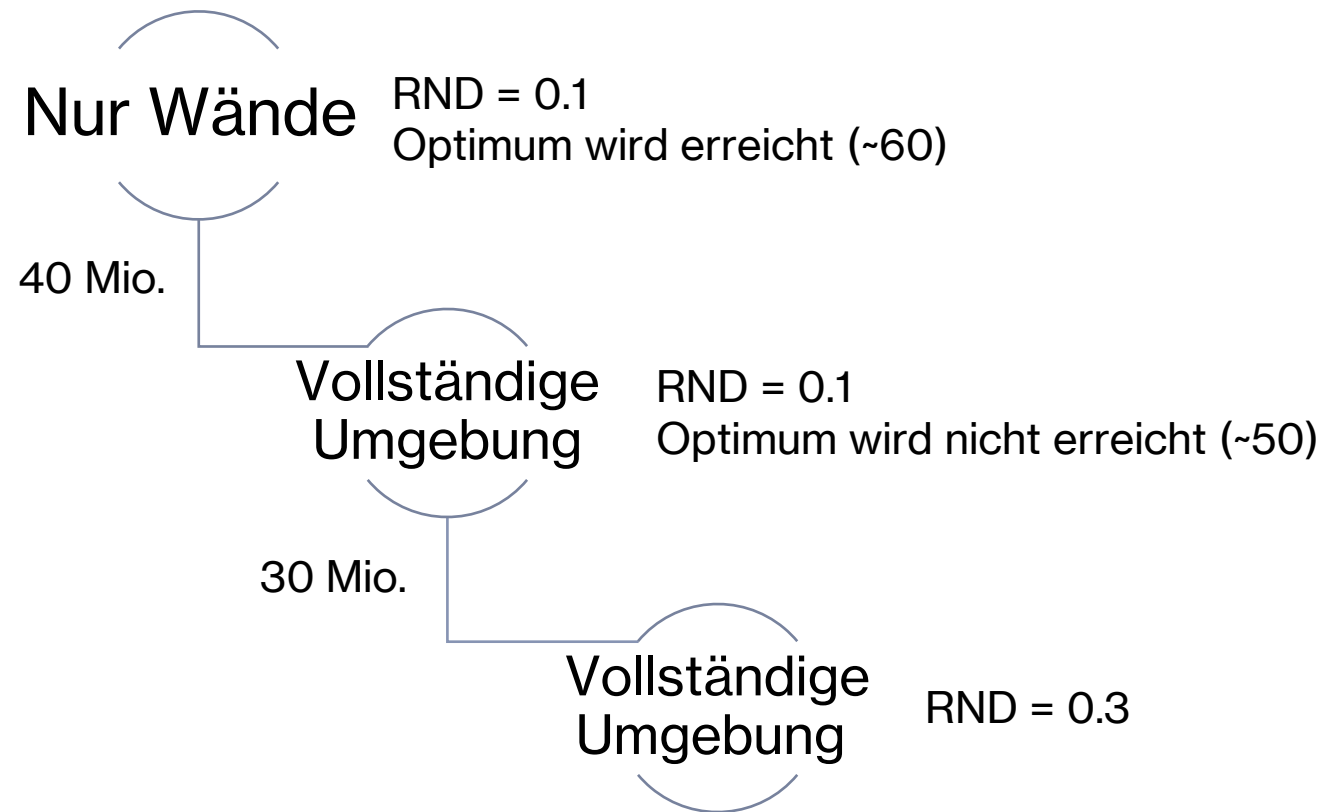
Curriculum-RND-Ansatz




Modell einsetzen in komplexe Umgebung




Curriculum-RND-Ansatz



Modell einsetzen in komplexe Umgebung





Live Demo

<https://koerners.github.io/Aeromarket/>


Erkenntnisse & Ausblick



Probleme

Problem	Lösung
Das nächste Ziel wird nicht korrekt angegeben	Kürzeste Distanz zum Zielobjekt wurde nicht aktualisiert (Skript)
Agent läuft nicht ins Exit	Position/Distanz zum Exit wurde nicht mitgegeben (Skript)
Aeorsole werden vom eigenen Agent als Hit erkannt → Punishment	Partikelsystem trifft den Collider für die Aerosole
Agenten stehen nicht auf dem Boden	Skin-Width = 0.0001
Wenn Skin-Width = 0 → Keine Kollisions-Erkennung mit anderen Agenten	Zusätzlicher Box-Collider
Zwischen-Ziele werden nicht optimal gefunden	Änderung der Observation-Angabe: Distanz → Position
Agenten können auf zu hohe Gegenstände springen	Step-Offset = 0
Agenten brauchen zu lange zum Lernen	Anpassung der Parameter (hidden units, num layer)

Ausblick



- Variabilität der Agententypen (jung/alt, mehr/wenige Einkäufe, Gruppe/Einzeln)
- Maßnahmen: mit/ohne Maske, mit/ohne Einkaufswagen
- Auf verschiedene Einkaufsumgebungen testen